

You Only Look Once (YOLO)

- Comprendre le problème de la détection d'objets
- Maîtriser l'architecture et le fonctionnement de YOLO
- Comparer YOLO aux autres approches (R-CNN, SSD)
- Comprendre l'entraînement, les fonctions de coût et les métriques
- Être capable d'implémenter et d'adapter YOLO à un cas industriel

Détection d'objets : définition

La **détection d'objets** consiste à :

- Localiser des objets dans une image (boîtes englobantes)
- Classifier chaque objet détecté

Sortie typique :

- Coordonnées de *bounding boxes*
- Classe de l'objet
- Score de confiance




Image illustrant la détection d'objets

Défis de la détection d'objets

- Variabilité d'échelle et de forme
- Occlusions
- Conditions d'éclairage
- Contraintes temps réel (vidéo, robotique)


- Fenêtre glissante + classificateur (HOG + SVM)
- Très coûteux en calcul
- Peu robuste aux variations

- R-CNN : propositions de régions + CNN
- Fast R-CNN : amélioration du temps
- Faster R-CNN : RPN (Region Proposal Network)

Limite : pipeline en plusieurs étapes, pas temps réel

YOLO = You Only Look Once

- La détection est formulée comme un **problème de régression**
- **Une seule passe** dans le réseau neuronal
- L'**image entière** est analysée globalement




Principe YOLO : prédiction directe des bounding boxes et classes

- **Très rapide** (détection en temps réel)
- **Architecture simple et unifiée**
- **Bonne généralisation** grâce à l'analyse globale

Inconvénient historique :


Précision plus faible sur les **petits objets**

Architecture de YOLO



Détection d'objets : définition

- Image divisée en une grille $S \times S$
- Chaque cellule prédit B *bounding boxes*
- Chaque *bounding box* est définie par :
 - Coordonnées (x, y, w, h)
 - Un score de confiance



Découpage de l'image en grille et prédiction
par cellule


Découpage de l'image



☐	dog	0.04
☐	cat	0.02
☒	chair	0.47
☐	...	
☐	coat	0.28
☐	car	0.11
☐	phone	0.03



☐	dog	0.03
☐	cat	0.05
☒	chair	0.27
☐	...	
☐	coat	0.24
☐	car	0.16
☐	phone	0.04



☐	dog	0.02
☐	cat	0.08
☐	chair	0.21
☐	...	
☒	coat	0.25
☐	car	0.13
☐	phone	0.05

Chaque cellule de la grille est associée à 20 valeurs (correspondant au nombre de catégories d'objets).

Découpage de l'image

Box 1

☐ x	20
☐ y	21
☐ w	250
☐ h	402
☐ confidence	0.67



Box 2

☐ x	160
☐ y	20
☐ w	122
☐ h	218
☐ confidence	0.21

Box 1

☐ x	20
☐ y	21
☐ w	250
☐ h	402
☐ confidence	0.67



Box 2

☐ x	160
☐ y	20
☐ w	122
☐ h	218
☐ confidence	0.21

Chaque cellule de la grille est donc associée à 10 valeurs (2 boîtes englobantes).

Découpage de l'image et vecteur de sortie



YOLO



$7 \times 7 \times 30$


20 indique les probabilités des classes en supposant qu'un objet est présent dans la cellule de la grille, et 10 correspond aux 2 boîtes englobantes ainsi qu'à la confiance.

Pour chaque cellule de la grille :

$$B \times (5 + C)$$

Avec :

- $5 = (x, y, w, h, \text{confidence})$
- C : nombre de classes



Structure du vecteur de sortie YOLO pour une cellule

L'entraînement de YOLO

Prend une image d'entraînement.




Diviser l'image en une grille de 7×7 cellules.



L'entrainement de YOLO


Utiliser les boîtes englobantes de vérité terrain

(ground truth).




Déterminer la cellule de la grille contenant les centres.

Ces cellules de grille sont responsables de la prédiction des boîtes englobantes.



L'entrainement de YOLO

Effectuer une propagation avant (forward pass) dans YOLO pour obtenir le tenseur, puis le comparer aux étiquettes afin de calculer la perte (loss).



Fonction de coût YOLO : Fonction de perte globale


La fonction de coût combine :

- Erreur de localisation
- Erreur de confiance
- Erreur de classification

L'entrainement de YOLO

Loss Function

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$



$$\lambda_{coord} \sum (x - \hat{x})^2 + (y - \hat{y})^2 + (\sqrt{w} - \sqrt{\hat{w}})^2$$


Pourquoi la racine sur w, h ?

- Réduire l'impact des grandes boîtes

L'entrainement de YOLO

Loss Function

$$\begin{aligned} \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & (C_i - \hat{C}_i)^2 \\ + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} & (C_i - \hat{C}_i)^2 \\ + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} & (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




C'est celle où se situe le centre de la boîte englobante.

L'entrainement de YOLO

Loss Function

$$\begin{aligned} \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & (C_i - \hat{C}_i)^2 \\ + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} & (C_i - \hat{C}_i)^2 \\ + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} & \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




Cette cellule de la grille prédit B = 2 boîtes englobantes.

L'entrainement de YOLO

Loss Function

$$\begin{aligned} \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & (C_i - \hat{C}_i)^2 \\ + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} & (C_i - \hat{C}_i)^2 \\ + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} & \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




Celle qui a la plus grande IoU avec la boîte englobante de référence est responsable de la détection du chien.

L'entrainement de YOLO

Loss Function

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




La différence est représentée par cette composante de la fonction de perte.

- Basée sur l'loU (Intersection over Union)
- Pénalise faux positifs et faux négatifs

L'entrainement de YOLO

Loss Function

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




Nous voulons également que la confiance de la boîte englobante responsable soit égale à l'IoU avec la vérité terrain.

L'entrainement de YOLO

Loss Function

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




Nous voulons également pénaliser (ou réduire) la boîte englobante prédite qui n'est pas responsable d'un objet. La confiance de la vérité terrain doit être égale à 0.

L'entrainement de YOLO

Loss Function

$$\begin{aligned} \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & \left[(\sqrt{w_i} - \sqrt{\hat{w}_i})^2 + (\sqrt{h_i} - \sqrt{\hat{h}_i})^2 \right] \\ + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} & (C_i - \hat{C}_i)^2 \\ + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} & (C_i - \hat{C}_i)^2 \\ + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} & (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$




Cette activation et cette suppression sont représentées par cette partie de la fonction de perte.

Définition de Intersection over Union (IoU)

$$IoU = \frac{\text{Surface Intersection}}{\text{Surface Union}}$$

- Mesure standard en détection d'objets
- Seuil typique : 0.5


Définition de l'IoU




La perte de classification

Loss Function

$$\begin{aligned} & \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[(x_i - \hat{x}_i)^2 + (y_i - \hat{y}_i)^2 \right] \\ & + \lambda_{\text{coord}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} \left[\left(\sqrt{w_i} - \sqrt{\hat{w}_i} \right)^2 + \left(\sqrt{h_i} - \sqrt{\hat{h}_i} \right)^2 \right] \\ & + \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{obj}} (C_i - \hat{C}_i)^2 \\ & + \lambda_{\text{noobj}} \sum_{i=0}^{S^2} \sum_{j=0}^B \mathbb{1}_{ij}^{\text{noobj}} (C_i - \hat{C}_i)^2 \\ & + \sum_{i=0}^{S^2} \mathbb{1}_i^{\text{obj}} \sum_{c \in \text{classes}} (p_i(c) - \hat{p}_i(c))^2 \end{aligned}$$



Cette perte de classification est représentée ici.




Post-traitement : Non-Maximum Suppression (NMS)


- Supprime les détections redondantes
- Basée sur l'IoU et le score

Non-Maximum Suppression (NMS)

- Sélectionner la boîte avec le score d'objectivité le plus élevé
- Comparer le chevauchement (intersection sur union, IoU) de cette boîte avec les autres boîtes
- Supprimer les boîtes englobantes dont le chevauchement (IoU) est supérieur à 50%
- Passer au score d'objectivité le plus élevé suivant
- Répéter les étapes 2 à 4



Step 1: Selecting Bounding box with highest score



Step 3: Delete Bounding box with high overlap




Step 5: Final Output

- YOLOv1 : réseau inspiré de GoogLeNet
- YOLOv2/v3 : Darknet-19 / Darknet-53
- YOLOv4/v5/v8 : architectures optimisées

Ancres : Principe des boîtes d'ancrage

- Les boîtes d'ancrage sont des boîtes englobantes prédéfinies de différentes formes
- Placées à chaque cellule de la carte de caractéristiques
- Le modèle prédit des décalages par rapport aux ancres
- Aide à détecter des objets de différentes tailles et proportions



Anchor box 1



Anchor box 2



Idée clé :

- Au lieu de prédire les boîtes à partir de zéro
- Partir d'une forme de référence et l'ajuster

- Prédiction à plusieurs résolutions
- Meilleure détection des petits objets

- Précision / Rappel
- Average Precision (AP)
- mAP (mean Average Precision)
- FPS (Frames Per Second)

Détection correcte (YOLO)

- Une prédiction est un **True Positive (TP)** si :
 - La classe est correcte
 - L'IOU avec la vérité terrain est supérieure à un seuil (ex. $IOU \geq 0.5$)

Équations

$$\text{Précision} = \frac{TP}{TP + FP} \quad \text{Rappel} = \frac{TP}{TP + FN}$$

Interprétation YOLO

- Précision élevée $\rightarrow$ peu de fausses détections
- Rappel élevé $\rightarrow$ peu d'objets manqués

Intersection over Union (IoU)

$$IoU = \frac{\text{Aire}(B_{pred} \cap B_{gt})}{\text{Aire}(B_{pred} \cup B_{gt})}$$

Dans YOLO

- IoU détermine si une prédiction est correcte
- Seuils typiques : IoU = 0.5 ou plusieurs seuils

Courbe Précision–Rappel

- Construite en faisant varier le seuil de confiance
- Une courbe par classe

Définition

- AP = aire sous la courbe Précision–Rappel pour une classe
- Calculée à un seuil IoU donné (ex. AP@0.5)

Équation (approximation discrète)

$$AP = \sum_n (R_n - R_{n-1}) \cdot P_n$$

YOLO Metrics

- AP@0.5 : IoU fixé à 0.5
- AP@0.75 : localisation plus stricte

mAP@0.5

- Moyenne des AP sur toutes les classes
- IoU fixé à 0.5

mAP@0.5 :0.95 (COCO)

- Moyenne des AP pour IoU = 0.5 :0.05 :0.95
- Mesure à la fois précision de classification et de localisation

Équation

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

Définition

- FPS : nombre d'images traitées par seconde
- Critique pour les applications temps réel

Équation

$$FPS = \frac{1}{\text{Temps d'inférence par image}}$$

YOLO

- YOLO = *You Only Look Once*
- Conçu pour maximiser le FPS tout en conservant une mAP élevée
- Compromis : YOLOv8-nano (rapide) vs YOLOv8-large (précis)

- VOC, COCO, Open Images
- Annotations : bounding boxes + classes

- Flip, rotation, scaling
- Mosaic, MixUp (YOLO récents)

Comparaison synthétique : Comparaison avec la famille R-CNN

Méthode	Vitesse	Performance
R-CNN	49 secondes	58%
Fast R-CNN	2.3 secondes	70%
Faster R-CNN	200 millisecondes	73%
YOLO	20 millisecondes	63%

- Véhicules autonomes
- Vidéosurveillance
- Robotique
- Industrie 4.0
- Imagerie médicale

- Objets très petits ou très denses
- Sensibilité aux données d'entraînement

- Transformers (YOLO + attention)
- Détection 3D
- Edge AI et optimisation embarquée

- YOLO est une référence pour la détection temps réel
- Compromis efficace entre vitesse et précision
- Très utilisé en recherche et en industrie

Temporary page!

L^AT_EX was unable to guess the total number of pages correctly. As there was some unprocessed data that should have been added to the final page this extra page has been added to the document. If you rerun the document (without altering it) this surplus page will go away, because L^AT_EX now knows how many pages to expect for this document.