

TP-6, Traitement de langage naturel (NLP)

Exercice 1 : nltk

Text = ["hello, python is a great language", "python is not a good programming language", "C++ has been used for years", " I loved that movie [12]"]

1. En utilisant les expressions régulières, écrire une fonction qui permet de supprimer les caractères spéciaux et les mots entre crochets des chaînes ci-dessus

En utilisant la bibliothèque **nltk**, écrire une fonction qui permet de

2. appliquer les stemming sur les chaînes de caractères ci-dessous
3. appliquer la tokenization, puis supprimer les stops words

Exercice 2 : CALCUL TF-IDF

- La base contient 1000 documents, calculer la TF-IDF du mot "compteur" dans le document d, sachant que le document d contient 12 mots dont 3 fois le mot compteur et que 70 textes contiennent également le mot "compteur"
- Le mot "compteur" apparaît toujours 3 fois dans le document d mais apparaît cette fois dans 900 documents

Exercice 3 : Modèle TF-IDF pour Résumer un Texte

1. Demandez un texte à l'utilisateur.
2. Calculez les scores TF-IDF des phrases.
3. Affichez les 3 phrases les plus importantes comme résumé.

Exercice 4 : Modélisation de Texte avec N-Grams

1. Demandez à l'utilisateur d'entrer un texte.
2. Construisez un modèle de N-grams.
3. Utilisez ce modèle pour générer un texte à partir d'une graine (mot de départ).

Exercice 5 : Analyse des sentiments

En exploitant les fonctions écrites dans l'exercice 1, développer une application basée sur ML pour l'analyse de sentiments.

Dataset a utilisée :

https://drive.google.com/file/d/19A_sROmn6QH_M5YY10yOnLj1Aw-juKI0/view?usp=sharing